

从 Demo 到 Production

什么样的 Agent 在企业真正可用？

从一个已上线项目，看 Agent 如何成为一项系统工程。

01 从跑通到可用

Demo 跑通了，为什么还不够？

03 系统工程

系统怎样持续运行，并不断改进？

02 真实项目演进

真实需求如何推动 Agent 演进？

04 面试深度

面试时，如何证明项目深度？

01

第一章

从跑通到可用

Demo 跑通了，为什么还不够？

一次正常运行 / 四个核心维度

01 从跑通到可用


02 项目演进

03 系统工程

04 面试深度

最初的事件与要素抽取 Agent

为政府主管部门提取风险事件并关联工商信息。先看一个简单例子。



示例文本：“9月1日，位于乙市的某设备有限公司暂停生产，原因尚不明确。”

从跑通一次，到持续可用，还缺什么？

四个核心维度，贯穿后续的项目演进与系统工程。

业务完成度

能否按业务语境判断，真正完成任务？

例：结合地点、角色与证据，确认具体企业主体。

系统工程

Agent 如何嵌入完整的数据与执行链路？

前置：数据处理与小模型；执行：状态与资源管理

错误控制

偏离预期后，能否发现、限制影响并恢复？

静默失败、重试与降级；重复写入需要幂等。

可观测与持续优化

能否还原经过、衡量结果，并验证修改？

Tracing / Trajectory → Eval → Optimization

先看业务如何完成任务，再看系统如何承接执行、控制错误并持续改进。

02

第二章


事件与要素抽取 Agent 的演进

业务需求如何推动工具、上下文与任务边界变化？

业务完成度 / 信息关联、外部调查与任务分工

Agent 背后的技术架构与数据流

面向政府主管部门的风险监测项目：数据加工、持久化服务与上层 Agent 协同工作。




事件与要素解析只是完整系统的一环；它处理的数据，还会被上层 Agent 继续使用。

现实世界的歧义

从只按名称查询，到结合上下文中的地点查询；Agent 与工具的数量没有增加。

同一简称命中多地候选；地点藏在另一段上下文里。
“去年刚进去时在甲市培训，年后才调到乙市。”
…… “我们厂里一直叫星禾，工牌上写的是 XH。”

文本 T · 节选




增加的是查询依据：地点帮助缩小候选，但事件地点不直接等于注册地址。

不完整信息下的探索

搜索接入时，工商确认被拆为 subagent；这里展开它内部的调查循环。

原文只有团队线索，没有地点 • 教学模拟
“星旅项目组让程序员先别来，什么时候恢复也没说。”

工商确认 subagent • 独立调查 Context



一次调查如何补充线索 • 模拟


- 01 搜索问题
星旅 研发团队 工作地点
- 02 查看搜索命中的招聘页
“星旅研发岗位 | 乙市”
页面列出用人主体：远帆软件有限公司
- 03 用新线索查询工商记录
名称：远帆软件有限公司；地区：乙市
获得候选后，仍需核验它与原文团队的关系。

搜索把团队线索转为可查询的企业候选；网页片段与核验过程留在调查 Context。

复杂任务中的分工

同一次演进，从主任务看分工：保留工商结论与依据，隔离中间调查材料。

若继续放在主 Agent：原文、事件要素与搜索片段、工商候选共用同一 Context。
工商确认目标相对独立；大量调查材料与主 Agent 的要素抽取关联较低。




统一社会信用代码是独立交付；隔离调查 Context，让主 Agent 保留事件抽取所需信息。

有限资源下的决策

全量解析视频成本太高，因此先处理标题与描述，再由信息缺口触发内容获取。


标题尚未说明：哪个厂区、哪一班次、何时发生？



读取结果回到主 Agent，影响地点、时间、事件范围与主体判断；获取失败时保留缺口。

任务边界与能力复用

能力从单个任务的内容补充，发展为多个调用方通过工具入口复用。



外层是一次 Tool Call，内部仍有独立 Agent Loop；按任务隔离 Context，返回相关内容与依据。

03

第三章


Agent 成为 系统工程

如何应对持续流量与失败，并验证每一次优化？

系统运行 / 错误控制 / 可观测与持续优化

质量与成本，取决于哪些环节？


橙色：主体误绑的下游影响；蓝色：用前置分类减少后续的深度处理。



沿来源追查结果，沿处理链路看资源消耗；前置筛选也必须评估漏筛。

海量数据，如何分配有限的计算资源？


先用低成本手段缩小处理范围，再把 Agent 调用留给需要深度判断的内容。



减少无效计算，把资源留给需要深度判断的任务；同时评估漏筛。

失败之后，系统如何继续？


工商主体尚未确认，Agent 却可能把失败当作空结果，或自行补齐企业。



恢复有边界，交付有依据；程序检查状态与引用，关联判断仍需 Eval。

结果提交超时，怎样避免重复写入？

AgentExecutor 提交抽取结果时，服务端已写入，调用方却没收到确认。



提交超时 ≠ 未写入；重试复用同一提交标识与结果，避免重复产生业务记录。

运行与改进，需要哪些证据？

从工具错误与写入重试，到主体判断是否正确，都需要可以检查的证据。

Test

约定的行为，
是否按规则执行？

构造故障，检查明确的预期

注入工商查询超时



错误状态仍为 error

模拟写入成功、响应丢失



相同 K、R 重试 → 不重复写入

单元测试 / 集成测试 / 故障注入

Tracing

这次任务，
是怎样执行的？

关联同一次任务的输入、调用与输出

输入
原文片段 / 时间元数据



调用
模型输入 / 工具参数与返回



输出
企业主体 / 关联依据 / 状态

保留调用关系、耗时与错误状态

Eval

面对业务任务，
系统表现如何？

在同一组代表性样本上比较版本

正常

信息不全

工具失败

主体、地点与时间判对了吗？

依据不足时，
保留未确认了吗？

修改后，质量、成本与延迟如何？

重复运行，观察表现与波动

Test 验证约定，Trace 还原执行，Eval 检验任务表现与改动效果。

Tracing：把一次执行展开来看

左侧展开同一次任务的调用关系，右侧查看选中调用的输入、输出、耗时与状态。

执行调用树

教学模拟

■ 事件与要素抽取

结束8.20 s

■ LLM · 抽取事件与线索

OK1.40 s

■ 工商确认 · subagent

结束5.30 s

■ LLM · 选择查询参数

OK1.00 s

■ search_companies

ERROR3.00 s

■ LLM · 生成主体结果

OK1.20 s

■ LLM · 汇总事件输出

OK1.30 s

点击调用查看详情 · 耗时与 Token 均为模拟

search_companies

tool_registry_01

TOOL · ERROR · 3.00 s

INPUT · 当次实际输入（节选）

arguments: {

"name": "星禾", "region": "乙市"

}

ERROR · 工具返回

status: "error"

error: {"type": "timeout"}

data: null

本次查询没有拿到可用工商记录。

点击后续“生成主体结果”，查看模型收到的错误。

父调用：工商确认 subagent

Trace 把模型与工具调用连起来：即使任务结束，也能追到中途的错误与后续输出。

18 / 30

Eval：先把业务要求写成指标

从业务错误出发，定义判断准则与统计口径。

业务要求	对应 Metrics
主体关联 确认要准确，有证据时也要找得到	Precision / Recall 同时检查误绑与漏绑
事件与证据 时间、地点、范围属于同一事件	关联正确率 / 证据支持率 按明确的判定准则逐项评分
不确定与失败 信息不足、工具失败时如实交付	无依据确认率 / 失败状态保留率 关注错误是否被后续输出掩盖
运行代价 质量满足后，比较资源消耗	单任务成本 / 延迟分位数 工具调用次数与失败次数

确认准确率 • Precision

正确确认的主体数
÷ 系统已确认的主体数

确认召回率 • Recall

正确确认的主体数
÷ 按现有证据应能确认的主体数

只减少关联，可能同时减少误绑与召回。
一律保留未知，也不算任务完成。

指标必须对应业务错误，并定义清楚分母；单一平均分无法解释每类任务表现。

从 Trace 到可重复运行的 Dataset

保存任务输入与工具环境，让后续版本能在同一条件下比较。



候选样本从哪里来？

随机抽样：保留普通任务分布

定向补充：误绑、超时、长尾

补齐正例：证据充分时应确认

只收集失败，会看不到正常任务
也无法解释总体线上表现。

Dataset Item · 文本 T / 教学模拟	
source_trace_id	trace_demo_18 → 保留原输出作对照
input	完整原文 + 页面 / 采集时间
tool_fixture	查询超时响应；无其他可用工商记录
expected	待标注、复核后确定
metadata	工具失败 / 无依据确认 / 来源与事件分组
评子任务时，保存它实际收到的输入；评端到端时，保存原始任务。	

原输出可以用来分析错误；参考答案需要另外确定，不能直接照抄 Agent 的回答。

谁来判断对错，怎样形成 Golden Set?

同一套判定准则，产生执行评分与可信参考两类不同的产物。

Code

比较标识、状态和确定性约束
例：已确认，却缺少工商记录
记录字段差异与规则评分

LLM Judge

按 rubric 判断角色与证据关系
输出标签、评分与引用依据
用人工标签校准，检查分歧

Human annotation

复核语义歧义与边界样本
修正参考答案，裁决标注分歧
保留判定理由与标注版本

共同的 rubric：评哪一项、什么算正确、何时应保留未确认

评分写回 Trace

本次输出：确认“星禾制造有限公司”
registry_record: null
标签：工具失败后无依据确认
回答“这次做得怎样”，用于归因与比较。

参考答案经复核 → Golden Set

主体：工商关联未确认
依据：查询超时，没有可用工商记录
保留星禾 / XH 线索，不凭名称补全企业
未经核验的自动标签保留为 Silver / 候选集。

评分回答这次做得怎样；Golden Set 保存可信的参考答案与判定依据。

Golden Set： 如何避免只记住样例？

按场景分类看表现，再按用途划分数据；可信的标签，并不意味着数据可以反复用于调参。

同一份 Golden Set，为样本打多维标签

材料与任务	文本 / 视频；完整事件 / 工商确认 / 内容获取
业务难点	招聘角色混淆 / 跨段地点 / 相对时间 / 事件范围
证据与执行	可确认正例 / 证据不足 / 工具失败 / 未读取视频

先按事件与来源归组，再划分集合；近重复和改写不跨集合

开发集 · 调整方案

调 Prompt / Tool / Context / 模型
允许反复分析失败与优化

验证集 · 比较候选

比较版本、参数和资源取舍
不作为 few-shot 示例


留出集 · 检查泛化

方案冻结后检查，发布前使用
不参与调参与方案选择

小样本可以启动迭代；泛化需要更广的覆盖、独立样本和持续的新流量。

离线 Eval：重新运行，再比较版本

每个候选版本重新执行任务，产生新的 Trace、输出与评分。



每次修改都重新运行 Agent；留出集在方案冻结后验证，不进入调参循环。

一次修改，怎样证明有效？

目标错误是否改善，其他能力是否保持，分别检查。

候选 B 的改动：明确工商确认所需证据，并增加结果接受检查
缺少工商记录的 confirmed 不予接受；保留失败与未确认，再用完整任务 Eval 检查表现。


检查什么	基线 A · 教学模拟	候选 B · 教学模拟
目标改善 · 工商查询超时	无记录，却确认星禾制造有限公司 confirmed · registry_record: null	保留超时；工商主体未确认
回归检查 · 相对时间	停工与通知分别保留相对时间	仍保留相对时间与未知基准
回归检查 · 视频范围	乙市二厂夜班暂停；白班继续	仍区分厂区与班次
回归检查 · 可确认证例	有充分证据，正确确认 UC_XH	仍然正确确认 UC_XH

正例补充证据（模拟）：厂区公示关联星禾 / XH 与注册主体；工商快照提供 UC_XH。

这是预期结果的教学示意；实际是否改善，要看新实验的分场景指标、成本与延迟。

让线上新问题进入下一轮 Eval

离线集覆盖不了持续变化的输入；线上评估负责发现新问题，并把它们沉淀下来。



让线上新问题进入版本化数据集，再用离线回归与线上观察验证下一次修改。

04

第四章

面试官如何 判断项目深度

怎样用真实证据讲清自己的工程判断？


架构选择 / 失败分析 / 效果验证 / 个人贡献

架构选择：为什么这样设计？

用一次具体决策，说明业务约束、备选方案与取舍。


业务要求：通过多轮调查，确定具体工商主体
工商确认相对独立；中间搜索过程与时间、地点、风险类型等要素抽取相关性低。

方案 A · 主 Agent 直接调查



取舍：交接少，调查与抽取共用上下文
主任务需要同时处理调查过程与其他要素。

方案 B · 委派工商 subagent




项目选择 B：隔离独立调查，返回相关结论与依据
代价：增加委派与交接，需要防止关键线索丢失。

拆分的依据是任务独立性与 Context 隔离需求；工具数量本身不足以决定架构。

失败分析：讲清一个非 Happy Path

先区分执行事实与根因假设，再说明修改位置和验证方式。

执行证据 · trace_demo_18 / 教学模拟



Test · 检查确定约束 故障注入；验证无记录的确认结果会被拦下。	Eval · 重新运行完整任务 检查失败处理、正常确认与语义关联是否退步。
---------------------------------------	--

事实支持什么判断？

本次错误没有被封装成“成功空结果”。
问题出现在错误传入后的主体确认。
还不能仅凭这条记录断定“换模型就能解决”。


可验证的修改假设

明确确认所需证据，检查结果接受条件。
无工商记录时保留未确认；
有记录时，还要核验它与原文的关联。

Trace 支持排查方向；修改是否有效，还需要明确的约束测试与完整任务评估。

效果验证：如何证明真的变好了？

同样一句“效果提高了”，背后可以是范围完全不同的证据。



结论应与证据范围匹配：说明验证了什么，也说明哪些部分仍然未知。

个人贡献：你做过哪些工程判断？

把负责的部分、实际修改和验证材料对应起来。



解释为什么这样工作，
定位为什么失败，
证明修改是否有效。

查询超时案例 · 教学模拟
明确确认所需证据，落实接收约束；
用 Trace 与 Eval 检查是否仍无依据确认。

明确区分：我提出过什么、实现过什么、验证过什么。