

VLM in Robotics

端侧 AI 的工程挑战与职业机会

课程地图（60 分钟）

- ① 端侧 vs 云侧：约束的本质差异
- ② 模型上端的完整技术链路
- ③ 端侧 Infra 的岗位方向与技能需求
- ④ 新人如何快速上手 - 分级项目指南
- ⑤ 未来 3 年的职业机会与选择



①

端侧 vs 云侧

从几千张卡到一颗芯片

云侧 Infra：关键词「规模」

核心问题：如何让几千张卡协同工作？

约束维度：

- 通信成本：AllReduce 效率、跨机房延迟
- 调度问题：任务分配和负载均衡
- 容错机制：节点挂掉后的重启策略

因此工作方向：

分布式框架 → 通信优化 → 集群调度 → 容错系统



端侧 Infra：关键词「约束」


核心问题：如何在小设备上跑大模型？

约束对比（云侧 → 端侧）：

- 算力：PetaFLOPS → TeraFLOPS（降 1000 倍）
- 内存：TB 级 → GB 级（降 1000 倍）
- 功耗：kW 级 → W 级（降 1000 倍）
- 发热：恒温机房 → 手机不超 50°C

因此工作方向：

量化压缩 → 图优化 → 编译适配 → 芯片充分利用



为什么选机器人作为例子

✓ 硬件多样性：CPU / GPU / NPU 混合

✓ 实时性明确：避障 $< 100\text{ms}$ 、抓取 $< 500\text{ms}$

✓ 多模态任务：视觉 + 语言 + 决策 + 控制

✓ 工程复杂性高：端云协同、离线可用

✓ 市场需求旺盛：工业、物流、家用、配送

→ 从机器人学到的技能可直接迁移到手机、无人机、车机



②

模型上端的完整链路

从 PyTorch 到运行在硬件上

链路全景： 6 个关键环节

- ① 模型选择： 7B / 4B / 2B ， 还是自己蒸馏
- ② 格式转换： PyTorch → ONNX → 目标框架
- ③ 量化压缩： FP32 → FP16 / INT8 / INT4
- ④ 图优化： 融合算子、内存复用、冗余删除
- ⑤ 编译生成： 编译为可执行代码（ CPU / GPU / NPU ）
- ⑥ Runtime 部署： 集成进机器人的控制框架



第一步：模型选择与蒸馏

现成的轻量级 VLM：

- LLaVA-Phi (2.7B) • MobileVLM (1.7B)
- Qwen 2B • LLaMA 2 7B


自己做蒸馏（保留精度）：

- 用大模型标注数据 → 蒸馏到小模型
- 成本：1 张 A100，2-3 天
- 收益：参数减半，精度掉点 <5%

选择原则：

高精度要求 → 用大一点的模型

成本优先 → 蒸馏或用现成小模型



第二步：格式转换与导出

为什么不能直接跑 PyTorch 模型：

- 不同硬件需要不同指令集
- 推理框架期望的格式不同
- 需要进行图优化和分析

标准链路：

PyTorch → `torch.onnx.export()`
→ `onnx-simplify` （清理冗余）
→ 导入目标框架（TVM / TensorRT）

验证工具：

- Netron：可视化模型结构
- `onnx-checker`：检查模型完整性



第三步：量化 - 最关键的优化

为什么必须量化：

FP32 : 4B 模型 = 16GB → 无法部署


FP16 : 8GB | INT8 : 4GB | INT4 : ~1GB

三种量化方法：

- ① PTQ : 快速，精度掉 3-8%
- ② QAT : 精度好，需要重训 1-2 天
- ③ 混合精度：关键层 FP16，其他 INT8

常见陷阱：

⚠ 不同层对量化敏感度不同 → 逐层调优必需



第四步：图优化与编译


优化三大目标：

- 计算：融合相邻算子（Conv+ReLU $\approx$ 1 个）
- 内存：激活复用、权重共享
- 访存：数据重排、缓存优化

主流编译工具：

- TVM：通用，自动调优
- ONNX Runtime：跨平台，快速验证
- TensorRT：NVIDIA GPU 专用，性能最优

编译时间：10 分钟 ~ 1 小时（取决于模型和芯片）



第五步： Runtime 选择与集成

推理引擎对标：


- llama.cpp：最轻量，CPU 优先
- ONNX Runtime：通用，多后端支持
- TensorRT：NVIDIA GPU 专用
- MLC-LLM：编译优先，性能好
- 厂商栈：QNN(高通) / CoreML(Apple)

集成进机器人框架：

编写 ROS Node → 监听话题（图像、指令）

→ 调用推理引擎

→ 发布结果给规划和控制模块



③

端侧 Infra 的岗位方向

新人入行该从哪个方向开始

方向 ①：模型压缩与量化

做什么：蒸馏 / 量化 / 剪枝，把模型变小

需要的能力：

- PyTorch / TensorFlow（框架）
- 统计学和信息论基础
- ONNX Quantizer / TensorQuantizer（工具）

难度：☒☒（相对容易）

新人适配度：★★★★★（最适合起点）



方向 ②：推理引擎与算子

做什么：实现高效推理框架和算子

需要的能力：

- C++ / CUDA
- 计算机体系结构（缓存、访存、SIMD）
- 算法优化和性能分析

难度：☒☒☒☒（困难）

新人适配度：★★☆☆☆（建议 2 年后切入）



方向 ③ : 芯片 /NPU 适配

做什么：把模型适配到具体芯片，利用加速器

需要的能力：

- 芯片文档（高通 QNN、华为 CANN、MTK APU）
- 编译与链接
- 性能分析工具（ profiler、tracer）

难度：☒☒☒☒☒（最困难）

新人适配度：★☆☆☆☆（专家路线）



方向 ④：端云协同与调度

做什么：决策哪些任务在端上跑，哪些上云

需要的能力：

- 系统设计与架构
- 网络协议（gRPC、protobuf）
- 实时系统和调度算法

难度：☒☒☒（中等）

新人适配度：★★★★☆☆（2年后考虑）



所有方向都需要的基础

- Linux / 操作系统：进程、内存、并行
- C++ / Python：编程语言
- 计算机体系结构：CPU / GPU / 缓存
- 性能分析：Profiler、perf、flamegraph

新人成长路线：

Month 1-2：量化项目 → Month 3-4：编译图优

Month 5-6：芯片适配 → Year 2：方向专化



④

新人快速上手指南

从零基础到能做项目

项目等级 ①：跑通量化与部署

目标时间：1 周内完成

做什么：

- ① 选开源小模型（LLaVA-Phi / MobileVLM）
- ② ONNX Quantizer 做 INT8 量化
- ③ llama.cpp 或 ONNX Runtime 部署
- ④ 测延迟、内存、功耗
- ⑤ 绘制精度 vs 速度对比图

交付物：benchmark 数据表 + 部署文档



项目等级 ②：分层推理与优化

目标时间：3-4 周


实现分层推理系统：

- 第一层：轻量级 CNN（ResNet18）快速过滤
- 第二层：VLM 精细化分析
- 测端到端延迟和准确率

或做蒸馏实验：

- 大模型标注数据 → 蒸馏到小模型
- 对标精度掉点和参数量关系

核心收获：从「跑通」升到「会优化」



项目等级 ③ : 完整应用产品

目标时间: 8-12 周

真实应用场景选一个:

- ✓ 工业检测: PCB 焊接缺陷识别
- ✓ 家用机器人: 理解「收拾客厅」指令
- ✓ 无人机避障: 实时障碍识别

需要包含的环节:

- ① 模型选择 ② 部署流程 ③ 实时集成
- ④ 性能分析 ⑤ 反馈迭代

这个项目能完全展示你的端侧工程能力



简历 / 面试准备

☒ 不要说：

「熟悉 PyTorch」 「用过 quantization API」

☒ 应该说：

「在 Jetson Orin 上部署 4B VLM，通过 INT4 量化和 KV Cache 优化，首字延迟从 2.5s 优化到 800ms」

「通过 mixed-precision 恢复精度到仅掉 2%」

「基于实测对比，选择了 llama.cpp」



⑤

未来 3 年的机会

为什么现在进入最好

技术演进的方向

方向 A：模型继续变小但不掉精度


- 蒸馏、剪枝、MoE 等技术成熟
- 2B 模型能力接近现在的 7B

方向 B：芯片能力飙升

- NPU 从高端流向中端手机
- 2026 年骁龙 8 Gen4 能力翻倍

方向 C：推理框架标准化

- 学习曲线下降，一键部署变现实
- 更需要懂优化的人



人才缺口在哪

云侧 Infra 已经卷：


- 大厂都有完整栈 • 开源方案成熟
- 新人难以突破

端侧 Infra 才起步：

- 机器人、无人机、汽车爆发需求
- 每个硬件都需深度优化
- 人才缺口： 3-5 倍于云侧

为什么端侧更缺人：

- ✍ 每个芯片都是独立工程
- ✍ 没有「一招鲜吃天下」
- ✍ 真正需要「会调」的人



职业发展的两条路

路径 A：广度 - 多平台通才

掌握 Jetson / 高通 / MTK / 海思 / Apple

→ 大厂 AI Infra / 推理框架创业公司

→ 天花板：技术负责人、架构师

路径 B：深度 - 领域专家

专注「机器人 / 无人机 / 汽车 / AR」

→ 初创公司 / 厂商 CTO

→ 天花板：产品 CTO

⚠ 前 3 年的选择决定 3-5 年后的天花板



现在最热的赛道

最高需求 + 融资最多：

- ☒ 工业机器人：ROI 清晰
- ☒ 物流仓储：DJI、极智嘉、快仓投入
- ☒ 家用移动机器人：需求旺盛
- ☒ 无人机航拍：边缘计算需求大
- ☒ 汽车智驾：芯片 + 算法结合

选择关键点：

- ✓ 能接触真实硬件 ✓ 性能可测
- ✓ 有反馈循环 ✓ 团队有高手



立即开始的行动清单

- ☐ 这周选一个开源小模型跑起来
- ☐ 下周做一版量化，对比性能差异
- ☐ 选择感兴趣的硬件平台深入
- ☐ 参与开源项目或找初创实习
- ☐ 建立「性能数据驱动」的思维
- ☒ 端侧 AI 不是未来，是现在。
每个设备上都在跑推理，缺的就是你。

